

DIDAMATICA 2026

Verifica documentale automatizzata con IA locale nella scuola

Sovranità sull'inferenza su hardware consumer

Giuseppe Mastrandrea · Laura Castellana

ITT Panetti-Pitagora · Bari



CHI SONO

Giuseppe Mastrandrea

Docente di informatica

Animatore digitale



Happy to connect

giuseppemastrandrea.github.io

01

Contesto

La scuola e il problema

CONTESTO

ITT Panetti-Pitagora - Bari

2

sedi

5

indirizzi

120

docenti

960

studenti

CAT

Informatica

Elettronica

Elettrotecnica

Chimica e materiali

Classi digitali: una scuola in cui il digitale fa già parte della didattica.

IL PROBLEMA

Fine anno: centinaia di documenti da controllare


- Relazioni finali, programmi svolti, verbali dei CdC
- Centinaia di file eterogenei, poche persone a controllarli uno per uno
- Tipo giusto? Anno scolastico corrente? Leggibile?



La segreteria a giugno, davanti ai caricamenti di fine anno

OGGI

Il flusso manuale



L'IDEA

Un LLM e un tool di automazione al posto dei tre passaggi



IL (NUOVO) PROBLEMA

LLM via API

Compliance

- Un nuovo responsabile esterno del trattamento
- Un nuovo trasferimento di dati, spesso extra UE
- Una nuova finalità: far interpretare i documenti a un modello

Rendicontazione spesa

- Pagamento a consumo, importo variabile
- Spesa ricorrente, difficile da rendicontare
- Fornitore spesso estero

E SE USASSIMO UN'API GRATUITA?



Per lavorare davvero bisogna pagare, e si torna alla **rendicontazione della spesa**.

02

Inferenza locale


La risposta al nuovo problema

DEFINIZIONE

Sovranità sull'inferenza

Inferenza: il modello legge il documento e risponde.

Sovranità: questo avviene su una macchina della scuola.



TESI

È alla portata di una scuola

- Su hardware di **costo ordinario**
- Con una perdita di qualità contenuta e, per una verifica formale, sostenibile

QUADRO NORMATIVO • DM 166/2025

Le Linee guida MLM chiedono proprio questo

- La scuola è **deployer** ai sensi dell'AI Act
- Sistemi di IA in **ambienti controllati**, sotto il controllo diretto del deployer
- LLM: niente conservazione dei prompt, profilazione o tracciamento

| Con l'inferenza locale queste raccomandazioni sono soddisfatte per costruzione.

SPESA

Una workstation, non un abbonamento

Workstation

Una tantum

Capitolo di spesa definito

Bene in inventario

Cloud a consumo

Ricorrente

Importo variabile con l'uso

Fornitore spesso estero

Un solo acquisto risolve **entrambe** le barriere: compliance e spesa.


03

Il sistema

Estrarre fatti, calcolare esiti

ARCHITETTURA


Una pipeline, un documento alla volta



Il contenuto dei documenti non lascia mai la workstation. Il modello estrae i fatti, il codice decide.

n8n: il flusso come diagramma

- Piattaforma di **automazione dei flussi di lavoro**: ogni passo è un nodo, i nodi sono collegati tra loro
- **Self-hosted**: gira sulla workstation della scuola
- Connettori pronti per Google Drive e Fogli, nodi di codice per le regole
- Il flusso si **legge** anche senza saper programmare




L'editor di n8n: nodi collegati da sinistra a destra

ARCHITETTURA • INFERENZA



Ollama: il modello come servizio locale



- Scarica e gestisce i modelli con un comando: `ollama pull gemma4:12b`
- Cambiare modello significa cambiare un nome nel flusso

Si usa come un'API cloud, ma l'indirizzo è la macchina della scuola.

ARCHITETTURA • MODELLI

Modelli open weight

Modello chiuso

Accessibile solo tramite l'API del fornitore

I pesi restano sui server del fornitore

Si paga a consumo, per ogni richiesta

Modello open weight

I pesi, cioè i parametri addestrati, sono scaricabili

Gira offline, sul proprio hardware

Nessun costo per richiesta

Open weight non vuol dire open source: i pesi sono pubblici, i dati e la procedura di addestramento non sempre.

DEMO

Il flusso n8n dal vivo



Apri il flusso in n8n ↗

`localhost:5678/workflow/DMvVqs2InKCdg81N`

AI ACT • ALLEGATO III

Fuori dall'alto rischio

- ✗ Non decide accesso o ammissione
- ✗ Non valuta i risultati di apprendimento
- ✗ Non monitora gli studenti

| Verifica amministrativa formale: la decisione finale resta a una persona.

04

Sperimentazione

Tre modelli, stesso compito

SPERIMENTAZIONE

Tre modelli open weight entro 16 GB di VRAM

- **gemma4:e4b**

Google · variante compatta

Riferimento minimo

- **gemma4:12b**

Google · 12 miliardi di parametri

Candidato

- **qwen3.5:9b**

Alibaba · 9 miliardi di parametri

Candidato

SPERIMENTAZIONE • DATASET

579 documenti reali, etichettati a mano

189

relazioni finali

314

programmi svolti

76

verbali CdC

valido

off topic

fuori perimetro

anno discordante

image only

Poison (negativi iniettati): ricette, circolari, determine, verbali di altri organi, relazioni di anni precedenti · [apri la cartella](#) ↗

Dataset non pubblico: contiene dati personali di docenti e studenti.

SPERIMENTAZIONE

Metriche

- **Recall sui non validi**: quanti documenti **non validi** il sistema riconosce davvero?
- **Falsi positivi**: quanti non validi passano come validi, contati uno per uno

05


Risultati

Cosa intercetta, cosa respinge a torto

RISULTATI • DOCUMENTI NON VALIDI

Quasi tutti i non validi vengono intercettati

recall sui non validi • FP = non validi approvati




I due candidati sono quasi perfetti: al massimo 2 non validi approvati per tipologia.

RISULTATI • DOCUMENTI VALIDI

Il quadro si rovescia sui validi respinti

validi respinti a torto, sul totale dei validi



Qwen non riconosce il tipo di documento: «questo non è un verbale».

SCELTA DEL MODELLO

In produzione: gemma4:12b

- **gemma4:12b**

Non validi intercettati: 0,94 – 1,00

Verbali validi respinti: **17 su 42**

Errori **spiegabili**: anno, organo collegiale

- **qwen3.5:9b**

Non validi intercettati: 0,97 – 1,00

Verbali validi respinti: **39 su 42**

Errori **sistematici**: non riconosce il tipo di documento

| Un modello locale adeguato alla verifica formale esiste, e gira su hardware consumer.

06

Conclusioni e sviluppi futuri

Limiti, lezioni, prossimi passi

RISULTATI

«Ma quindi non devo smistare i verbali?»»

— Raffaella, segreteria didattica

SVILUPPI FUTURI

Un modello dedicato, addestrato in casa

- **Fine-tuning** di un modello piccolo sui documenti già etichettati a mano
- Sulla stessa workstation, con **QLoRA**: si addestrano solo piccoli adattatori sul modello a 4 bit

CREDITS

Autori

Giuseppe Mastrandrea

`giuseppe.mastrandrea@panettipitagora.edu.it`

Laura Castellana

`dirigente@panettipitagora.edu.it`

| ITT Panetti-Pitagora · Bari

Domande?

